

KF 기반 센서 재구성과 Bayesian Feature Modeling 설계

Jaewoong Han

I. 모델 체계와 기호

이 문서에서 비교할 네 가지 KF 계열 모델은 다음과 같이 정리한다.

기호는 다음처럼 구분한다.

- x_k : 시각 k 의 차량 동역학 상태
- c_k : 측정 가능한 제어·외생 입력, 예: wheel torque
- r_k : front/rear road height 또는 bump input
- o_k : IMU, wheel speed 등 실제 관측 센서
- p : 질량, 관성, 강성, 감쇠 등 차량 물리 파라미터
- τ_{ui} : 사용자 u , 구간 i 에서 downstream hierarchical Bayesian model에 들어가는 feature
- y_{ui} : 기존 hierarchical Bayesian model의 outcome

중요하게도 KF가 추정하는 state, road라는 unknown input, offline에서 맞추는 차량 파라미터는 서로 다른 대상이다.

II. 큰 틀에서 KF의 기본 수식 설계

A. 연속시간 차량 모델

선형 차량 모델의 가장 일반적인 형태는 다음과 같다.

$$\dot{x}(t) = A_c(p)x(t) + B_c(p)c(t) + E_c(p)r(t) + w(t)$$

$$o(t) = C_c(p)x(t) + D_c(p)c(t) + J_c(p)r(t) + v(t)$$

여기서

$$w(t) \sim \mathcal{N}(0, Q_c), \quad v(t) \sim \mathcal{N}(0, R_c)$$

이다. w 는 process/model error, v 는 sensor measurement error이다.

샘플링 간격 Δt 로 이산화하면

$$x_{k+1} = A_d x_k + B_d c_k + E_d r_k + w_k$$

$$o_k = C_d x_k + D_d c_k + J_d r_k + v_k$$

이며, zero-order hold를 가정할 때

$$\begin{aligned} A_d &= e^{A_c \Delta t}, \\ B_d &= \int_0^{\Delta t} e^{A_c \tau} B_c d\tau, \\ E_d &= \int_0^{\Delta t} e^{A_c \tau} E_c d\tau \end{aligned}$$

로 구성한다. 이는 Kalman의 선형 state-space filtering 틀에 해당한다 [1].

B. A, B 와 차량 파라미터의 offline 추정

현재처럼 KF를 실행하기 전에 dynamics parameter를 calibration data로 맞출 수 있다.

$$\hat{p} = \arg \min_p \left[\sum_{k=1}^T \|o_k - \hat{o}_k(p)\|_W^2 + \lambda \mathcal{R}(p) \right]$$

그 후

$$A_d^* = A_d(\hat{p}), \quad B_d^* = B_d(\hat{p})$$

를 KF에서 사용한다.

가능하면 A, B 의 원소를 완전히 자유롭게 맞추기보다

$$p = \{m_s, I_y, m_{uf}, m_{ur}, k_{sf}, k_{sr}, c_{sf}, c_{sr}, k_{tf}, k_{tr}, \dots\}$$

와 같은 물리 파라미터나, 안정성이 보장되는 modal parameter를 맞춘 뒤 A, B 를 계산하는 편이 좋다. 그래야 음의 질량·감쇠나 불안정 pole 같은 비물리적 해를 방지할 수 있다.

C. Kalman filter prediction-correction

Road가 known input이면 r_k 를 그대로 사용하고, road를 추정하지 않는 모델이면 해당 항을 제거한다.

1) Prediction:

$$\hat{x}_{k|k-1} = A_d \hat{x}_{k-1|k-1} + B_d c_{k-1} + E_d r_{k-1}$$

$$P_{k|k-1} = A_d P_{k-1|k-1} A_d^\top + Q$$

2) Innovation과 gain:

$$e_k = o_k - (C_d \hat{x}_{k|k-1} + D_d c_k + J_d r_k)$$

$$S_k = C_d P_{k|k-1} C_d^\top + R$$

$$K_k = P_{k|k-1} C_d^\top S_k^{-1}$$

3) Correction:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k e_k$$

수치적으로 안정적인 Joseph form은

$$\begin{aligned} P_{k|k} &= (I - K_k C_d) P_{k|k-1} (I - K_k C_d)^\top \\ &\quad + K_k R K_k^\top \end{aligned}$$

이다.

TABLE I
비교할 네 가지 KF 계열 모델

번호	차량 모델	Road/bump 처리	추정기	연구상 역할
1	축약 bounce-pitch body model	명시적 road 추정 없음	Linear KF	현재 코드에 가장 가까운 baseline
2	2-DOF quarter-car	Road height/rate를 상태에 증강	Augmented linear KF	가장 단순한 road-estimation baseline
3	4-DOF linear half-car	단일 spatial road profile과 front-rear delay	Augmented 또는 joint input-state KF + RTS smoother	선형 주 후보
4	vehicle_model.py nonlinear half-car	Bump profile/parameter를 latent state로 추정	EKF + smoother	비선형 확장 후보

D. 재구성 신호와 feature

KF posterior로부터 측정 불가능한 센서 신호를 계산한다.

$$\hat{s}_k = H_\tau \hat{x}_{k|k}$$

예를 들어

$$\hat{s}_k = \begin{bmatrix} \hat{z}_{sk} \\ \hat{\theta}_k \end{bmatrix}$$

가 bounce rate와 pitch rate가 된다. 한 window의 down-stream feature는

$$\hat{\tau}_{ui}^{KF} = \Phi(\hat{s}_{1:T}, o_{1:T})$$

로 계산한다. Φ 는 RMS, peak, standard deviation, derivative feature 등을 만드는 기존 feature extractor이다.

E. Bump 통과가 끝난 뒤의 smoothing

온라인 제어가 아니라 한 구간 전체가 수집된 뒤 feature를 복원하는 목적이라면 filtering만 쓰기보다 Rauch-Tung-Striebel smoother를 추가하는 것이 적절하다.

$$G_k = P_{k|k} A_d^\top (P_{k+1|k})^{-1}$$

$$\hat{x}_{k|T} = \hat{x}_{k|k} + G_k (\hat{x}_{k+1|T} - \hat{x}_{k+1|k})$$

$$P_{k|T} = P_{k|k} + G_k (P_{k+1|T} - P_{k+1|k}) G_k^\top$$

Xue et al.도 half-car road reconstruction에서 augmented KF와 RTS smoothing을 결합한다 [2].

III. 기존 BAYESIAN MODEL에 추가하는 세 가지 설계

세 방법은 같은 residual을 서로 다르게 표현한 것이 아니다.

- Feature residual: 최종 τ 의 복원오차를 보정
- Dynamics residual: 매 time step의 상태전이 오차를 보정
- Road bump estimation: vehicle error가 아니라 물리적인 미지 외란 r_k 를 복원

초기 모델에서는 세 항을 모두 자유롭게 동시에 추정하면 안 된다. 특히 dynamics residual과 road input은 동일한 진동을 서로 대신 설명할 수 있어 식별성이 크게 떨어진다.

A. Feature residual을 Bayesian하게 추정

1) Calibration data: 일부 calibration 구간에서 실제 target sensor를 측정할 수 있다고 가정한다.

$$\hat{\tau}_{ui,j}^{KF} = \Phi_j(\hat{x}_{ui,1:T})$$

$$r_{ui,j}^\tau = \tau_{ui,j}^{true} - \hat{\tau}_{ui,j}^{KF}$$

2) Bayesian residual regression:

$$r_{ui,j}^\tau = q_{ui}^\top \beta_j + b_{u,j} + \epsilon_{ui,j}$$

$$\epsilon_{ui,j} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma_{\tau,j}^2)$$

$$\beta_j \sim \mathcal{N}(0, \lambda_{\beta,j}^2 I),$$

$$b_{u,j} \sim \mathcal{N}(0, \omega_j^2),$$

$$\sigma_{\tau,j} \sim \text{HalfNormal}(s_j)$$

여기서 β_j 는 Beta 분포가 아니라, speed · torque · bump 조건 등이 residual 평균에 미치는 영향을 나타내는 회귀계수 벡터이다. 예를 들면

$$q_{ui} = \begin{bmatrix} 1 & \bar{v}_{ui} & T_{ui}^{peak} & a_{x,ui}^{RMS} \end{bmatrix}^\top$$

로 둘 수 있다.

따라서 실측할 수 없는 feature의 조건부 평균을

$$\mu_{ui,j}^\tau = \hat{\tau}_{ui,j}^{KF} + q_{ui}^\top \beta_j + b_{u,j}$$

로 두면,

$$\tau_{ui,j}^{mis} | \mu_{ui,j}^\tau, \sigma_{\tau,j} \sim \mathcal{N}(\mu_{ui,j}^\tau, \sigma_{\tau,j}^2)$$

가 된다.

q_{ui} 가 필요하지 않은 가장 단순한 시작 모델은

$$\tau_{ui,j}^{mis} \sim \mathcal{N}(\hat{\tau}_{ui,j}^{KF} + b_{u,j}, \sigma_{\tau,j}^2)$$

이다.

위 식은 KF posterior mean을 offset으로 쓰는 가장 단순한 형태이다. KF/EKF가 covariance까지 출력하도록 구현하면 더 완전하게

$$x_{ui,1:T}^{(m)} \sim p_{KF}(x_{ui,1:T} | o_{ui,1:T})$$

$$\tau_{ui,j}^{(m)} = \Phi_j(x_{ui,1:T}^{(m)}) + q_{ui}^\top \beta_j + b_{u,j} + \epsilon_{ui,j}^{(m)}$$

로 state-reconstruction uncertainty와 feature-residual uncertainty를 함께 전달할 수 있다. 따라서 현재 코드가 state mean만 반환한다면 $P_{k|k}$ 또는 smoothed trajectory draw도 반환하도록 수정해야 한다.

3) 기존 *hierarchical Bayesian model*과의 결합: 기존 사용자별 coefficient 구조를 유지한다.

$$\gamma_u \sim \mathcal{N}(\mu_\gamma, \Sigma_\gamma)$$

관측 · 복원 feature를

$$\tilde{\tau}_{ui} = \begin{bmatrix} \tau_{ui}^{obs} \\ \tau_{ui}^{mis} \end{bmatrix}$$

로 묶는다. 이진 outcome을 예로 들면

$$y_{ui} | \tilde{\tau}_{ui}, \gamma_u \sim \text{Bernoulli}[\text{sigmoid}(\gamma_u^\top \tilde{\tau}_{ui})]$$

최종 예측은 feature posterior를 적분한다.

$$p(y_{ui} | o_{ui}, \mathcal{D}) = \int p(y_{ui} | \tau_{ui}, \gamma_u) \times p(\tau_{ui}^{mis} | o_{ui}, \mathcal{D}) p(\gamma_u | \mathcal{D}) d\tau d\gamma$$

즉 Normal 객체를 단순히 기존 `fit()`에 넣는 것이 아니라, posterior draw를 사용하거나 joint model 안에서 latent feature를 직접 샘플링한다.

이 설계와 통계적으로 가장 가까운 문헌은 Bayesian covariate-measurement-error와 latent-predictor model이다. Bartlett and Keogh는 true covariate를 latent하게 두고 outcome model까지 uncertainty를 전달하며, Schofield는 추정된 latent variable을 predictor로 쓸 때 measurement error를 함께 반영한다 [3], [4]. 물리모델 출력 뒤의 discrepancy라는 관점에서는 Kennedy-O'Hagan calibration과 대응한다 [5].

B. Dynamics residual을 Bayesian하게 추정

A^*, B^* 또는 nonlinear dynamics parameter $\hat{p}$ 를 먼저 맞추면 뒤 다음과 같이 둔다.

1) 선형식:

$$x_{k+1} = A^* x_k + B^* c_k + E^* r_k + d_k + w_k$$

가장 단순한 systematic bias는

$$d_k = b_x, \quad b_x \sim \mathcal{N}(0, \Sigma_b)$$

이다. 상태 · 입력 조건에 따라 error가 달라지면

$$d_k = W \phi(x_k, c_k)$$

$$\text{vec}(W) \sim \mathcal{N}(0, \Lambda_W)$$

로 둔다.

2) Nonlinear 식:

$$x_{k+1} = F_d(x_k, c_k, r_k; \hat{p}) + d(x_k, c_k) + w_k$$

$$d(\cdot) \sim \mathcal{GP}(0, k_d)$$

처럼 residual function에 Gaussian-process prior를 둘 수도 있다. BayesRace는 nominal vehicle model과 실제 transition 간 residual을 GP로 보정하며 [6], GP state-space model은 latent state와 transition dynamics를 fully Bayesian하게 함께 추정한다 [7].

3) 무엇이 Bayesian 확장인가:

$$w_k \sim \mathcal{N}(0, Q)$$

를 고정된 Q 와 함께 추가하는 것만으로는 이미 일반 KF와 같다. Bayesian dynamics residual이라고 부르려면 최소한

$$p(b_x, W, Q | o_{1:T}, c_{1:T})$$

또는

$$p(d(\cdot), Q | o_{1:T}, c_{1:T})$$

를 추정해야 한다.

100 Hz raw transition residual은 시간상관이 남을 가능성이 높으므로, IID가 맞지 않으면

$$d_{k+1} = \rho_d d_k + \eta_k, \quad \eta_k \sim \mathcal{N}(0, Q_d)$$

와 같은 colored residual이 더 적절하다.

State posterior sample마다 feature를 계산하면

$$x_{1:T}^{(m)} \sim p(x_{1:T} | o_{1:T})$$

$$\tau_{ui}^{(m)} = \Phi(x_{1:T}^{(m)})$$

이므로 dynamics uncertainty가 downstream feature까지 전달된다.

C. Road bump를 Bayesian하게 추정

Road bump는 vehicle-model residual이 아니라 별도의 물리적 unknown input이다.

$$x_{k+1} = F_d(x_k, c_k, r_{f,k}, r_{r,k}; p) + w_k$$

$$o_k = h(x_k, c_k, r_{f,k}, r_{r,k}; p) + v_k$$

초기 bump 모델에서는 dynamics discrepancy d_k 를 빼고, 고정 또는 사전 calibration된 vehicle model을 사용한다.

1) 하나의 공간 profile: Front axle의 진행 위치를 s_k 라고 하면

$$s_{k+1} = s_k + v_{x,k} \Delta t$$

$$r_{f,k} = \rho(s_k)$$

$$r_{r,k} = \rho(s_k - L)$$

이다. $L = a + b$ 는 wheelbase이다. 일정 속도일 때 이는

$$r_r(t) = r_f \left(t - \frac{L}{v} \right)$$

와 같다. Zhu et al.도 front/rear road excitation을 wheelbase와 speed에 따른 delay로 연결한다 [8].

2) 형태가 알려진 *speed bump: parametric Bayesian inverse problem*: Bump가 하나의 매끄러운 돌출부라고 가정하면

$$\rho(s; \alpha) = \frac{h_b}{2} \left[1 - \cos\left(\frac{2\pi(s - s_0)}{L_b}\right) \right] \times \mathbf{1}(0 \leq s - s_0 \leq L_b)$$

$$\alpha = [h_b \quad L_b \quad s_0]^\top$$

로 둘 수 있다.

$$h_b \sim \text{HalfNormal}(s_h),$$

$$L_b \sim \text{LogNormal}(\mu_L, \sigma_L^2),$$

$$s_0 \sim \mathcal{N}(\mu_s, \sigma_s^2)$$

처럼 prior를 두고

$$p(x_{0:T}, \alpha \mid o_{1:T}, c_{1:T})$$

를 추정한다. 높이 · 폭 · 위치라는 소수의 파라미터만 추정하므로 현재처럼 vertical suspension sensor가 제한된 상황에서 가장 식별하기 쉽다.

3) 형태를 모르는 *road: nonparametric spatial state*: 공간 grid j 에서

$$\begin{bmatrix} \rho_{j+1} \\ \rho'_{j+1} \end{bmatrix} = \begin{bmatrix} 1 & \Delta s \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \rho_j \\ \rho'_j \end{bmatrix} + \eta_j$$

와 같은 smooth random-walk prior를 둘 수 있다. 이 경우 front와 rear가 같은 ρ 를 서로 다른 위치에서 읽도록 buffer 또는 batch spatial smoother가 필요하다.

4) 대표 추정 방법: 이론적으로는 **joint state-unknown input estimation** 또는 **augmented-state nonlinear state-space estimation**이다.

- 선형 · 온라인: augmented KF 또는 minimum-variance joint input-state estimator
- 비선형 · 온라인: augmented EKF/UKF
- bump 통과 후 전체 복원: EKF/UKF + RTS-type smoother
- posterior가 강하게 비Gaussian이면: particle smoother

Gillijns and De Moor는 state와 unknown input을 함께 minimum-variance unbiased하게 추정하는 재귀식을 제시한다 [9]. 차량 road-profile 사례로는 quarter-car augmented KF를 사용한 Doumiani et al.과, half-car에 AKF · regularization · RTS smoothing을 결합한 Xue et al., half-car joint input-state 추정을 사용한 Zhu et al.이 직접적인 근거이다 [2], [8], [10].

D. 세 Bayesian 설계의 최종 역할

권장 조합은 다음과 같다.

calibrated vehicle dynamics + latent bump +KF/EKF smoother +Bayesian feature residual +hierarchical outcome model
--

Dynamics residual과 bump를 동시에 자유롭게 추정하는 모델은 초기 주모델로 두지 않는다.

IV. KF 모델 4개 최종 내용

A. 모델 1 — 축약 *bounce-pitch linear KF*

1) 근거 논문의 기본 차량 수식: Half-car vertical dynamics는 일반적으로 다음 2차계 형태로 표현된다.

$$M\ddot{q} + C\dot{q} + Kq = S_r r(t) + S_c c(t)$$

$$q = [z_s \quad \theta \quad z_{uf} \quad z_{ur}]^\top$$

Zhu et al.도 차량의 mass, damping, stiffness matrix를 이용하여

$$M\ddot{Y} + C\dot{Y} + KY = S_p F(t)$$

로 쓰고, 이를

$$\dot{X} = \begin{bmatrix} 0 & I \\ -M^{-1}K & -M^{-1}C \end{bmatrix} X + \begin{bmatrix} 0 \\ M^{-1}S_p \end{bmatrix} F$$

로 변환한다 [8, eqs. (7)–(9)].

- 차량 형태: front-rear를 포함하는 longitudinal half-car
- 원 논문의 online 추정 대상: vehicle response state와 unknown road force/input
- 원 논문의 고정 파라미터: M, C, K 에 들어가는 질량 · 관성 · 강성 · 감쇠
- 현재 모델 1에서는 위 full half-car 중 low-frequency sprung-body bounce와 pitch mode만 남긴다.

2) 우리 수정 모델 수식: 현재 코드에 가까운 상태를

$$x_k = [x_{b,k}^\top \quad d_k^\top]^\top,$$

$$x_{b,k} = [z \quad \dot{z} \quad \theta \quad \dot{\theta}]^\top,$$

$$d_k = [\eta_z \quad \eta_\theta \quad b_z \quad g_r]^\top$$

로 둔다.

연속시간 gray-box 식은 다음처럼 정리할 수 있다.

$$\ddot{z} = -\omega_z^2 z - 2\zeta_z \omega_z \dot{z} + \kappa_a a_x + \eta_z$$

$$\ddot{\theta} = c_{z\theta} \dot{z} - \omega_\theta^2 \theta - 2\zeta_\theta \omega_\theta \dot{\theta} + g_a a_x + g_T T_w + g_{\Delta a} \Delta a_{fr} + \eta_\theta$$

Colored excitation과 bias는

$$\eta_{z,k+1} = \rho_z \eta_{z,k} + \xi_{z,k}$$

$$\eta_{\theta,k+1} = \rho_\theta \eta_{\theta,k} + \xi_{\theta,k}$$

$$b_{z,k+1} = b_{z,k} + \xi_{b,k}, \quad g_{r,k+1} = g_{r,k} + \xi_{g,k}$$

로 둔다.

관측식은

$$o_{z,k} = \ddot{z}_k + b_{z,k} + \nu_{z,k}$$

TABLE II
세 BAYESIAN 설계의 역할

설계	보정 · 추정 대상	권장 위치	초기 연구에서의 역할
Feature residual	RMS · peak 등 최종 feature error	KF와 hierarchical outcome model 사이	주 Bayesian feature model
Dynamics residual	매 time-step vehicle transition error	KF/EKF process model 내부	별도 ablation
Road bump	물리적 외부 입력 $\rho(s)$ 또는 bump parameter	KF/EKF state/input layer	Bump 실험에서 필수

$$o_{x,k} - \dot{v}_{x,k} \simeq g\theta_k + g g_{r,k} + b_x + \nu_{x,k}$$

이다. IMU 좌표계 · 부호에 따라 $g\theta$ 항의 부호는 실제 calibration으로 확정해야 한다.

- 수정 이유:
 - 현재 센서에는 suspension deflection과 wheel vertical acceleration이 없으므로 full road-input model 보다 관측 가능한 저차 body mode부터 안정적으로 복원한다.
 - bump를 물리적인 road height로 분리하지 않고 η_z, η_θ 가 미모델링 excitation을 흡수한다.
 - torque와 front-rear wheel-speed-derived acceleration difference를 pitch excitation으로 사용한다.
- 사용하는 센서:
 - vertical IMU acceleration: o_z
 - longitudinal IMU acceleration: o_x
 - 네 바퀴 wheel speed: $v_x, \dot{v}_x, \Delta a_{fr}$ 계산
 - wheel/motor torque estimate: T_w
 - roll rate: 이 2D 모델에서 추정하지 않고 측정값을 그대로 사용
- Online 추정 state:
 - $z, \dot{z}, \theta, \dot{\theta}$
 - colored excitation η_z, η_θ
 - vertical bias b_z , grade-like state g_r
- Offline 최적화 대상:
 - $\omega_z, \zeta_z, \omega_\theta, \zeta_\theta$
 - $c_{z\theta}, K_a, g_a, g_T, g_{\Delta a}$
 - Q, R 또는 그 diagonal scale
- 최종 재구성:
 - bounce rate: $\hat{z}$
 - pitch rate: 부호정의에 따른 $\pm \dot{\theta}$
- 한계:
 - unsprung mass와 tire가 없으므로 bump height · width를 물리적으로 복원할 수 없다.
 - 이 모델에서 road는 상태가 아니라 process excitation이다.

B. 모델 2 — Quarter-car augmented KF

1) 근거 논문 수식: Doumiati et al.의 2-DOF quarter-car는 sprung mass m_s 와 unsprung mass m_u 로 구성된다.

$$m_s \ddot{z}_s = -k_s(z_s - z_u) - c_s(\dot{z}_s - \dot{z}_u)$$

$$m_u \ddot{z}_u = k_s(z_s - z_u) + c_s(\dot{z}_s - \dot{z}_u) - k_t(z_u - r) - c_t(\dot{z}_u - \dot{r})$$

논문은 road를 unknown state에 포함하여

$$x_k = [z_s \quad \dot{z}_s \quad z_u \quad \dot{z}_u \quad r \quad \dot{r}]^\top$$

$$x_{k+1} = A_k x_k + w_k$$

로 둔다. Road prior는

$$\ddot{r} = 0$$

인 constant-slope/random-walk 형태이다. 논문의 observation은

$$o_k = [z_s - z_u \quad z_s \quad \dot{z}_s]^\top$$

이다 [10, eqs. (1)–(4)].

Chaabane et al.도 quarter-car에서 road input을 상태에 붙여

$$x_{k+1}^a = \begin{bmatrix} A_d & B_d \\ 0 & I \end{bmatrix} x_k^a + \begin{bmatrix} w_k \\ \eta_k \end{bmatrix}$$

$$o_k = [C \ D] x_k^a + v_k$$

인 augmented KF를 사용한다 [11, eq. (3.5)].

- 차량 형태: 차체 1/4과 한 wheel/axle을 나타내는 2-DOF quarter-car
- 원 논문의 online 추정 대상:
 - $z_s, \dot{z}_s, z_u, \dot{z}_u$
 - road height r 와 road rate $\dot{r}$
- 원 논문의 고정 파라미터:
 - $m_s, m_u, k_s, c_s, k_t, c_t$
- 원 논문의 센서:
 - vertical acceleration
 - suspension deflection
 - 적분으로 얻은 body displacement
- pitch와 roll은 모델에 포함되지 않는다.

2) 우리 수정 모델 수식: 현재 센서만 사용할 때 vertical observation은

$$o_k = a_{z,k}^{IMU}$$

로 단순화한다. 여기서

$$a_{z,k}^{IMU} = \ddot{z}_{s,k} + b_{z,k} + \nu_{z,k}$$

이다. Wheel speed로 얻은 v_x 는 quarter-car vertical KF의 correction에 직접 넣기보다

$$s_{k+1} = s_k + \bar{v}_{w,k} \Delta t$$

로 road를 시간축에서 공간축으로 바꾸는 보조 입력으로 사용한다.

Speed bump의 형태가 대략 알려져 있다면 자유로운 $(r, \dot{r})$ random walk보다

$$r_k = \rho(s_k; \alpha), \quad \alpha = [h_b \quad L_b \quad s_0]^\top$$

로 제한하는 것이 현재 센서 구성에서는 더 적절하다.

• 수정 이유:

- 논문이 사용하는 suspension deflection sensor가 현재 데이터에는 없으므로 동일한 observability를 주장할 수 없다.
- 자유 road state는 body vertical acceleration 하나와 강하게 confound되므로, known bump shape 또는 informative prior가 필요하다.
- quarter-car는 pitch를 표현하지 못하므로 pitch-rate reconstruction의 최종 모델이 아니라 road-estimation ablation으로 사용한다.

• 사용하는 센서:

- vertical IMU acceleration
- 네 wheel speed 평균으로 얻은 v_x 와 이동거리 s
- torque는 순수 quarter-car vertical 식에는 직접 사용하지 않음

• Online 추정 대상:

- $z_s, \dot{z}_s, z_u, \dot{z}_u$
- 제한된 road state 또는 bump parameter
- 필요하면 b_z

• Offline 고정 · calibration 대상:

- $m_s, m_u, k_s, c_s, k_t, c_t, Q, R$

• 한계:

- 현재 센서만으로 arbitrary road profile amplitude를 안정적으로 식별하기 어렵다.
- bounce 검증용 baseline에는 유용하지만 pitch target에는 구조적으로 부족하다.

C. 모델 3 — Linear half-car joint state-road estimation

1) 근거 논문 수식: Zhu et al.은 half-car 계열 차량의 동역학을

$$M\ddot{Y} + C\dot{Y} + KY = S_p F(t)$$

로 두고

$$X_{k+1} = A_d X_k + B_d F_k + w_k$$

$$Z_k = G X_k + J F_k + v_k$$

로 이산화한다. Acceleration, velocity, displacement selection matrix를 S_a, S_v, S_d 라 하면

$$G = [S_d - S_a M^{-1} K \quad S_v - S_a M^{-1} C]$$

$$J = S_a M^{-1} S_p$$

이다 [8, eqs. (7)–(13)].

해당 논문의 unknown-input update는

$$\tilde{R}_k = G P_{k|k-1} G^\top + R$$

$$M_k = \left(J^\top \tilde{R}_k^{-1} J \right)^{-1} J^\top \tilde{R}_k^{-1}$$

$$\hat{F}_{k|k} = M_k \left(Z_k - G \hat{X}_{k|k-1} \right)$$

로 road input을 먼저 구한 뒤 state를 update한다.

Xue et al.은 bounce와 pitch를 포함하는 half-car를 사용하고, front와 rear에서 추정된 동일 road profile의 일치도를 목적함수로 삼아 vehicle parameter를 최적화한 뒤 AKF, regularization, RTS smoothing으로 road를 복원한다 [2].

• 차량 형태:

- Zhu: equipment를 포함한 상세 2D half-vehicle
- Xue: bounce-pitch와 front/rear unsprung motion을 포함한 half-car

• 원 논문의 online 추정 대상:

- body · axle state
- front/rear road input

• Xue의 offline identification:

- front/rear road-profile consistency를 이용한 vehicle mechanical parameter 최적화

• 원 논문의 핵심 제약:

- front와 rear wheel은 같은 road를 wheelbase/speed만큼 시간차를 두고 통과

2) 우리 수정 차량 수식: 현재 목적에는 standard 4-DOF passenger half-car로 단순화한다.

$$\delta_f = z_s + a\theta - z_{uf}, \quad \delta_r = z_s - b\theta - z_{ur}$$

$$F_{sf} = k_{sf} \delta_f + c_{sf} \dot{\delta}_f$$

$$F_{sr} = k_{sr} \delta_r + c_{sr} \dot{\delta}_r$$

$$F_{tf} = k_{tf}(z_{uf} - r_f), \quad F_{tr} = k_{tr}(z_{ur} - r_r)$$

정적 평형을 원점으로 두고 upward-positive sign convention을 쓰면

$$m_s \ddot{z}_s = -F_{sf} - F_{sr}$$

$$I_y \ddot{\theta} = -a F_{sf} + b F_{sr} + M_T$$

$$m_{uf} \ddot{z}_{uf} = F_{sf} - F_{tf}$$

$$m_{ur} \ddot{z}_{ur} = F_{sr} - F_{tr}$$

Torque-induced pitch moment는 가장 단순하게

$$M_T = \lambda_T T_w$$

로 두거나, longitudinal tire force를 계산할 수 있으면

$$F_x = \frac{T_w}{R_{\text{eff}}}, \quad M_T = -h_{cg}F_x$$

로 물리 경로를 사용한다.
상태는

$$q = [z_s \quad \theta \quad z_{uf} \quad z_{ur}]^T, \\ x = [q^T \quad \dot{q}^T]^T$$

이다.

Road는 두 개의 독립 random walk가 아니라

$$r_{f,k} = \rho(s_k), \quad r_{r,k} = \rho(s_k - L)$$

로 묶는다.

현재 센서에 맞춘 observation은

$$a_{z,k}^{IMU} = \ddot{z}_{s,k} + x_I \ddot{\theta}_k + b_{z,k} + \nu_{z,k}$$

$$a_{x,k}^{IMU} - \dot{v}_{x,k} \simeq g\theta_k + b_{x,k} + \nu_{x,k}$$

$$v_{w,k}^{f/r} \simeq v_{x,k} + \nu_{v,k}^{f/r}$$

로 둔다.

• 수정 이유:

- 원 Zhu 모델의 equipment DOF는 일반 passenger vehicle 센서 재구성에 불필요하므로 제거한다.
- 현재 센서에는 suspension displacement와 axle vertical acceleration이 없으므로, J 가 두 road input에 대해 full column rank라고 보장할 수 없다.
- 따라서 instant direct-input update보다 하나의 spatial road profile, front-rear delay, informative prior, full-window smoothing을 함께 사용한다.
- longitudinal torque가 pitch에 주는 영향을 명시한다.

• 사용하는 센서:

- vertical IMU acceleration
- longitudinal IMU acceleration
- front/rear axle별 평균 wheel speed
- wheel/motor torque estimate
- roll rate는 2D half-car 밖이므로 측정값 pass-through

• Online 또는 smoothed 추정 대상:

- $z_s, \theta, z_{uf}, z_{ur}$ 와 각 속도
- bounce rate $\dot{z}_s$, pitch rate $\dot{\theta}$
- 하나의 road profile $\rho(s)$ 또는 bump parameter α
- IMU bias b_z, b_x

• Offline 최적화 대상:

- 우선 $k_{sf}, k_{sr}, c_{sf}, c_{sr}, k_{tf}, k_{tr}, \lambda_T, Q, R$
- 질량·관성은 차량 제원값을 우선 고정
- 모든 질량·강성·감쇠와 bump amplitude를 동시에 자유롭게 맞추지 않음

• 장점:

- 모델 2와 달리 bounce와 pitch를 동시에 표현한다.
- front-rear delay가 bump의 식별성을 높인다.

• 한계:

- current sensor set에서는 road height와 suspension parameter가 여전히 confound될 수 있으므로 observability/Fisher-information 검사가 필요하다.

D. 모델 4 — *vehicle_model.py* 기반 nonlinear EKF

1) EKF의 기본 원리: Nonlinear state-space model은

$$x_{k+1} = F_d(x_k, c_k) + w_k$$

$$o_k = h(x_k, c_k) + v_k$$

로 쓴다. EKF는 현재 추정점에서 1차 Taylor linearization을 수행한다. 비선형 차량 상태추정에서는 UKF도 대표적인 대안이며 [12], nonlinear half-vehicle multibody model과 augmented/constrained EKF를 결합한 직접적인 사례도 있다 [13].

Jacobian은

$$F_k = \left. \frac{\partial F_d}{\partial x} \right|_{\hat{x}_k|k, c_k}$$

$$H_k = \left. \frac{\partial h}{\partial x} \right|_{\hat{x}_k|k-1, c_k}$$

이다.

Prediction은

$$\hat{x}_{k+1|k} = F_d(\hat{x}_k|k, c_k)$$

$$P_{k+1|k} = F_k P_k|k F_k^T + Q$$

이고, correction은

$$e_{k+1} = o_{k+1} - h(\hat{x}_{k+1|k}, c_{k+1})$$

$$S_{k+1} = H_{k+1} P_{k+1|k} H_{k+1}^T + R$$

$$K_{k+1} = P_{k+1|k} H_{k+1}^T S_{k+1}^{-1}$$

$$\hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + K_{k+1} e_{k+1}$$

이다.

2) *vehicle_model.py*의 원래 형태: 앞서 확인한 코드의 상태는

$$v = [\dot{z}_s \quad \dot{\theta} \quad \dot{z}_{uf} \quad \dot{z}_{ur} \quad v_x]^T,$$

$$q = [z_s \quad \theta \quad z_{uf} \quad z_{ur} \quad s]^T,$$

$$X = [v^T \quad q^T]^T$$

이며

$$\dot{X} = f_{\text{veh}}(X, T_w, r_f, r_r; p)$$

형태이다.

- 차량 형태: bounce, pitch, front/rear unsprung motion, longitudinal speed를 결합한 nonlinear 4-DOF half-car
- 원 코드의 known input:

- wheel/motor torque
- front/rear road profile r_f, r_r
- 원 코드의 dynamic state:
 - sprung/unsprung vertical velocities and displacements
 - pitch rate and pitch angle
 - longitudinal speed and traveled position
- 원 코드에서 road는 추정 대상이 아니라 주어진 입력이었다.
- 3) 우리 수정 nonlinear dynamics: Suspension force를

$$F_{sf} = f_{sf}(\delta_f, \dot{\delta}_f; p)$$

$$F_{sr} = f_{sr}(\delta_r, \dot{\delta}_r; p)$$

로 두면 linear spring-damper, nonlinear stiffness, saturation을 모두 포함할 수 있다.

$$F_{tf} = f_{tf}(z_{uf} - r_f), \quad F_{tr} = f_{tr}(z_{ur} - r_r)$$

Torque와 longitudinal force는

$$F_x = \text{sat}\left(\frac{T_w}{R_{\text{eff}}}\right)$$

$$\dot{v}_x = \frac{F_x - F_{\text{roll}}(v_x) - F_{\text{aero}}(v_x)}{m_{\text{tot}}}$$

로 둔다.

Vertical/pitch dynamics는

$$\ddot{z}_s = \frac{-F_{sf} - F_{sr}}{m_s}$$

$$\ddot{\theta} = \frac{-aF_{sf} + bF_{sr} - h_{cg}F_x}{I_y}$$

$$\ddot{z}_{uf} = \frac{F_{sf} - F_{tf}}{m_{uf}}$$

$$\ddot{z}_{ur} = \frac{F_{sr} - F_{tr}}{m_{ur}}$$

로 쓸 수 있다. 실제 구현에서는 `vehicle_model.py`가 사용하는 좌표·pitch 부호와 위 식을 하나로 통일해야 한다.

4) Known road를 latent bump로 변경: 원래 입력이던 r_f, r_r 를

$$r_{f,k} = \rho(s_k; \alpha)$$

$$r_{r,k} = \rho(s_k - L; \alpha)$$

로 교체한다.

Parametric bump이면 augmented state를

$$X_k^a = [X_k^\top \quad \alpha^\top \quad b_z \quad b_x]^\top$$

로 두고

$$\alpha_{k+1} = \alpha_k + \eta_{\alpha,k}$$

로 천천히 변하거나 거의 고정된 parameter처럼 추정한다. 실제로 하나의 bump만 통과한다면 $\eta_{\alpha,k}$ 를 매우 작게 두고, filter 후 batch smoother 또는 MAP refinement를 수행하는 편이 안정적이다.

Actuator lag가 중요하면 실제 wheel torque도 state로 둔다.

$$T_{w,k+1} = a_T T_{w,k} + b_T T_{\text{cmd},k} + \xi_{T,k}$$

$$T_{\text{est},k} = T_{w,k} + \nu_{T,k}$$

5) 우리 sensor observation model:

$$a_{z,k}^{IMU} = \ddot{z}_{s,k} + x_I \ddot{\theta}_k + b_{z,k} + \nu_{z,k}$$

$$a_{x,k}^{IMU} = \dot{v}_{x,k} + g \sin \theta_k + b_{x,k} + \nu_{x,k}$$

작은 pitch에서는 $g \sin \theta \simeq g\theta$ 이다.

$$v_{w,k}^f \simeq v_{x,k} + \nu_{vf,k}$$

$$v_{w,k}^r \simeq v_{x,k} + \nu_{vr,k}$$

Slip이 큰 구간에서는 wheel speed를 곧바로 v_x 로 쓰지 말고 covariance를 키우거나 slip state를 추가해야 한다.

• 수정 이유:

- 원 코드의 known road input을 bump latent variable로 전환해야 한다.
- position s 는 road가 known time series일 때는 제거 가능하지만, 공간 bump $\rho(s)$ 를 추정할 때는 반드시 유지하는 것이 유리하다.
- torque command와 실제 torque estimate의 차이가 크면 actuator state를 추가한다.
- accelerometer bias를 state로 추가하여 gravity projection과 low-frequency drift를 분리한다.
- $h_b, L_b > 0$ 제약은 $\log h_b, \log L_b$ 를 state로 두어 만족시키고, bump 시작·끝의 indicator는 smooth gate로 근사하거나 filter 후 batch MAP에서 다룬다.
- saturation의 hard corner는 Jacobian이 불연속이므로 smooth saturation을 쓰거나, 비선형성이 강하면 UKF로 교체한다.

• 사용하는 센서:

- vertical IMU acceleration
- longitudinal IMU acceleration
- four-wheel speed; front/rear average와 slip consistency 계산
- motor/wheel torque command 및 estimate
- roll rate는 2D 모델에 포함하지 않고 measured channel을 그대로 사용

• EKF/smoothing 추정 대상:

- $\dot{z}_s, \dot{\theta}, \dot{z}_{uf}, \dot{z}_{ur}, v_x$
- $z_s, \theta, z_{uf}, z_{ur}, s$
- bump parameter (h_b, L_b, s_0) 또는 제한된 spatial profile

- b_z, b_x 와 필요 시 actual torque T_w
- Offline 고정 · calibration 대상:
 - 질량, 관성, wheelbase, CG height
 - suspension/tire stiffness and damping
 - rolling/aero resistance coefficient
 - Q, R 와 초기 covariance
- 추정하지 말아야 할 초기 항목:
 - 자유로운 vehicle dynamics residual과 자유로운 road profile을 동시에 추정하지 않음
 - 모든 물리 파라미터와 bump height를 동시에 on-line state로 두지 않음
- 검증:
 - calibration 구간에서 실제 bounce/pitch-rate sensor는 EKF observation에 넣지 않고 reconstruction target/validation으로 남긴다.
 - normalized innovation squared, state covariance consistency, bump parameter credible interval을 함께 평가한다.

V. 최종 연구 구성

A. 권장 비교 실험

1. **Model 1: reduced linear KF**
 - 현재 baseline
 - point feature만 downstream model에 입력
2. **Model 1 + Bayesian feature residual**
 - dynamics는 그대로 유지
 - 교수님의 feature-level Bayesian modeling 효과만 분리해 검증
3. **Model 3: linear half-car + latent bump + RTS smoother**
 - bump를 물리적 unknown input으로 추정
 - bounce/pitch feature를 posterior sample로 생성
4. **Model 4: nonlinear vehicle_model.py EKF + latent bump + smoother**
 - nonlinear dynamics의 추가 이득 검증
 - Model 3 대비 성능이 실제로 좋아지는지 비교
5. **Dynamics residual model**
 - 별도 ablation
 - bump model과 동시에 자유롭게 두지 않고, known/controlled-road calibration에서 먼저 검증

B. 최종 주모델

현재 센서 제약과 bump 통과 상황을 함께 고려하면 가장 방어하기 쉬운 주모델은

Model 3 또는 4 + latent spatial bump
+ front-rear wheelbase constraint + smoother
+ Bayesian feature residual

이다.

Model 3은 선형성과 식별성 때문에 주 분석에 더 안전하고, Model 4는 nonlinear extension 또는 성능 비교모델로 두는 것이 합리적이다. vehicle_model.py의 nonlinear EKF가 충분히 안정적이고 실제 hold-out data에서 Model 3보다 좋아질 때 Model 4를 최종 주모델로 승격한다.

C. 반드시 명시할 한계

- 현재 sensor set에는 suspension deflection과 wheel vertical acceleration이 없으므로, 기존 road-profile 논문과 동일한 관측가능성을 자동으로 얻지 못한다.
- Wheel speed는 bump의 공간 위치와 front-rear delay를 알려주지만 vertical amplitude를 직접 측정하지 않는다.
- Bump height, tire stiffness, suspension stiffness를 모두 자유롭게 추정하면 scale confounding이 생긴다.
- 2D half-car는 roll을 추정하지 못하므로 roll은 측정 channel을 유지하거나 별도의 full-car/roll model이 필요하다.
- 한 번도 target sensor를 측정하지 않은 경우 feature residual model의 bias와 variance를 데이터만으로 식별할 수 없다. 적어도 calibration 구간의 target sensor 또는 강한 물리 prior가 필요하다.

REFERENCES

- [1] R. E. Kalman, "A new approach to linear filtering and prediction problems," *Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960, doi: 10.1115/1.3662552.
- [2] K. Xue, T. Nagayama, and B. Zhao, "Road profile estimation and half-car model identification through the automated processing of smart-phone data," *Mechanical Systems and Signal Processing*, vol. 142, Art. no. 106722, 2020, doi: 10.1016/j.ymssp.2020.106722.
- [3] J. W. Bartlett and R. H. Keogh, "Bayesian correction for covariate measurement error: A frequentist evaluation and comparison with regression calibration," *Statistical Methods in Medical Research*, vol. 27, no. 6, pp. 1695–1708, 2018, doi: 10.1177/0962280216667764.
- [4] L. S. Schofield, "Correcting for measurement error in latent variables used as predictors," *The Annals of Applied Statistics*, vol. 9, no. 4, pp. 2133–2152, 2015, doi: 10.1214/15-AOAS877.
- [5] M. C. Kennedy and A. O'Hagan, "Bayesian calibration of computer models," *Journal of the Royal Statistical Society: Series B*, vol. 63, no. 3, pp. 425–464, 2001, doi: 10.1111/1467-9868.00294.
- [6] A. Jain, M. O'Kelly, P. Chaudhari, and M. Morari, "BayesRace: Learning to race autonomously using prior experience," in *Proc. Conf. Robot Learning*, PMLR, vol. 155, pp. 1918–1929, 2021.
- [7] R. Frigola, F. Lindsten, T. B. Schön, and C. E. Rasmussen, "Bayesian inference and learning in Gaussian process state-space models with particle MCMC," in *Advances in Neural Information Processing Systems 26*, 2013.
- [8] J. Zhu, X. Chang, X. Zhang, Y. Su, and X. Long, "A novel method for the reconstruction of road profiles from measured vehicle responses based on the Kalman filter method," *Computer Modeling in Engineering & Sciences*, vol. 130, no. 3, 2022, doi: 10.32604/cmescs.2022.019140.
- [9] S. Gillijns and B. De Moor, "Unbiased minimum-variance input and state estimation for linear discrete-time systems," *Automatica*, vol. 43, no. 1, pp. 111–116, 2007, doi: 10.1016/j.automatica.2006.08.002.
- [10] M. Doumiani, A. Victorino, A. Charara, and D. Lechner, "Estimation of road profile for vehicle dynamics motion: Experimental validation," in *Proc. American Control Conference*, pp. 5237–5242, 2011.
- [11] M. M. Chaabane, D. B. Hassen, M. S. Abbes, S. C. Baslamisli, F. Chaari, and M. Haddar, "Road profile identification using estimation techniques: Comparison between independent component analysis and Kalman filter," *Journal of Theoretical and Applied Mechanics*, vol. 57, no. 2, pp. 397–409, 2019, doi: 10.15632/jtam-pl/104592.
- [12] S. Antonov, A. Fehn, and A. Kugi, "Unscented Kalman filter for vehicle state estimation," *Vehicle System Dynamics*, vol. 49, no. 9, pp. 1497–1520, 2011, doi: 10.1080/00423114.2010.527994.
- [13] A. Débarbouillé, F. Renaud, Z. Dimitrijevic, D. Chojnacki, L. Rota, and J.-L. Dion, "Wheel forces estimation with an augmented and constrained extended Kalman filter applied on a nonlinear multi-body model of a half vehicle," *Procedia Structural Integrity*, vol. 38, pp. 342–351, 2022, doi: 10.1016/j.prostr.2022.03.035.